

ETL CONTAINER PROJECT

Creación y contenerización de una aplicación web con Flask para realizar una ETL

Infraestructuras de computación



Bernat Sort Rufat

MÁSTER UNIVERSITARIO EN DATA SCIENCE

11 de diciembre de 2022

Tabla de contenidos

Introducción.....	1
Desarrollo del código Python con el framework Flask	1
Organización del proyecto	1
Creación del entorno virtual e instalación de paquetes	1
Código Fuente para la ETL.....	2
Contenerización de la aplicación con Docker	9
Dockerfile	9
Generación de la imagen.....	10
Creación del volumen.....	10
Ejecución de la imagen en un contenedor.....	11
Comprobaciones finales	16


Introducción

Este proyecto consta, por una parte, de crear una aplicación web que utilice el framework Flask para extraer datos de la API de Star Wars (SWAPI), transformarlos y cargarlos (ETL), y, por otra parte, crear una imagen de esta aplicación con Docker para empaquetarla dentro de un contenedor y poderla desplegar y ejecutar en cualquier sistema compatible con Docker.

Desarrollo del código Python con el framework Flask

Organización del proyecto

El proyecto consta de una carpeta llamada *src* que contiene el código fuente de la aplicación, así como las bases de datos e imágenes que se crearán en la parte de carga de datos, una carpeta *venv* que contiene toda la configuración de mi entorno virtual, un archivo llamado *requirements.txt* con los paquetes que mi aplicación necesita para funcionar, y finalmente, el archivo *Dockerfile*.



Creación del entorno virtual e instalación de paquetes

Primero de todo, creamos un entorno virtual para mantener la aplicación aislada de otras aplicaciones y lo activamos.



Instalamos todos los paquetes necesarios para que la aplicación funcione, por ejemplo, Flask. Todos los paquetes instalados los ponemos en el archivo requirements.txt.

```
~/Doc/M/c/f/venv/bin flask_ETL_sw at 22:31:10
pip3 install flask
Collecting flask
  Using cached Flask-2.2.2-py3-none-any.whl (101 kB)
Collecting Jinja2>=3.0
  Using cached Jinja2-3.1.2-py3-none-any.whl (133 kB)
Collecting click>=8.0
  Using cached click-8.1.3-py3-none-any.whl (96 kB)
Collecting itsdangerous>=2.0
  Using cached itsdangerous-2.1.2-py3-none-any.whl (15 kB)
Collecting Werkzeug>=2.2.2
  Using cached Werkzeug-2.2.2-py3-none-any.whl (232 kB)
Collecting MarkupSafe>=2.0
  Using cached MarkupSafe-2.1.1-cp310-cp310-macosx_10_9_universal2.whl (17 kB)
Installing collected packages: MarkupSafe, itsdangerous, click, Werkzeug, Jinja2, flask
Successfully installed Jinja2-3.1.2 MarkupSafe-2.1.1 Werkzeug-2.2.2 click-8.1.3 flask-2.2.2 itsdangerous-2.1.2
```

```
requirements.txt
1 certifi==2022.12.7
2 charset-normalizer==2.1.1
3 click==8.1.3
4 Flask==2.2.2
5 Flask-SQLAlchemy==3.0.2
6 idna==3.4
7 itsdangerous==2.1.2
8 Jinja2==3.1.2
9 kaleido==0.2.1
10 MarkupSafe==2.1.1
11 numpy==1.23.5
12 pandas==1.5.2
13 Pillow==9.3.0
14 plotly==5.11.0
15 python-dateutil==2.8.2
16 pytz==2022.6
17 requests==2.28.1
18 six==1.16.0
19 SQLAlchemy==1.4.44
20 tenacity==8.1.0
21 urllib3==1.26.13
22 Werkzeug==2.2.2
```

Código Fuente para la ETL

El código fuente del proyecto se encuentra en la carpeta *src*. Consta de cuatro archivos .py (app, extract, transform y load) y una carpeta llamada *templates* con los archivos HTML. Nos centraremos en comentar únicamente los archivos Python para no extender demasiado la explicación del proyecto.

```
FLASK_ETL_SW
├── src
│   ├── __pycache__
│   ├── templates
│   │   ├── films.html
│   │   ├── index.html
│   │   ├── people.html
│   │   ├── planets.html
│   │   ├── plots.html
│   │   ├── species_table.html
│   │   └── starships_plot.html
│   ├── app.py
│   ├── extract.py
│   ├── load.py
│   └── transform.py
```

Extracción de los datos (Extract)

Como hemos mencionado anteriormente, los datos se extraen de la API de Star Wars, llamada SWAPI.

Esta API en realidad se divide en 6 sub-APIs: una para los personajes (*people*), otra para los planetas (*planets*), para las películas (*films*), las especies (*species*), los vehículos (*vehicles*) y finalmente para las naves espaciales (*starships*).

```
# APIs
people_url = 'https://swapi.dev/api/people/'
planets_url = 'https://swapi.dev/api/planets/'
films_url = 'https://swapi.dev/api/films/'
species_url = 'https://swapi.dev/api/species/'
vehicles_url = 'https://swapi.dev/api/vehicles/'
starships_url = 'https://swapi.dev/api/starships/'
```

Para poder extraer toda la información de la API que deseemos, en el archivo *extract.py* se crea la clase *Extract()* que contiene una función que extrae todos los datos de la API en cuestión y los almacena en una lista.

```
extract.py x
src > extract.py > ...
1  import requests
2
3  class Extract():
4      # Función que extrae todos los datos de la API de Star Wars (SWAPI)
5      def extract_paginated_data(self, url) -> list[dict]:
6          # lista vacía para almacenar los datos
7          all_data = []
8          # hacemos peticiones a la API hasta que no haya más páginas con datos
9          while url:
10             # petición GET a la API para extraer los datos
11             response = requests.get(url)
12             # parseamos los datos JSON
13             data = response.json()
14             # añadimos los datos de la página actual a la lista de todos los datos
15             all_data.extend(data["results"])
16             # url de la próxima página o None si no hay más páginas
17             url = data["next"]
18             # devolvemos una lista con los datos
19             return all_data
```

Transformación de los datos (Transform)

En la clase Transform, se han definido una serie de funciones que permiten:

- Guardar en una lista todos los valores de una determinada clave de un diccionario, como, por ejemplo, el nombre de todos los personajes, planetas y películas de Star Wars.
- Generar una tupla con dos listas: una con los n valores más elevados de una determinada clave de un diccionario, y la otra con los respectivos valores de otra clave. Por ejemplo, crear una lista con la población de los 10 planetas más poblados y otra con los nombres de dichos planetas, o crear una lista con el precio de las 10 naves espaciales más caras y otra con los nombres de esas naves espaciales.
- Iterar sobre los elementos de una lista de diccionarios y, para cada elemento, crear un objeto que contenga los valores de los campos clave_1 y clave_2. Cada objeto se añade a la lista, y se devuelve dicha lista. Por ejemplo, para las distintas especies de personajes de Star Wars, generar una lista con el nombre de la especie y su clasificación.
- Generar gráficos de barras utilizando la librería *plotly.express* a partir de dos listas. Por ejemplo, un gráfico de barras del top 10 de naves espaciales más caras o un top 10 de los planetas con más habitantes.

Todos estos ejemplos comentados se han implementado en las diferentes rutas del programa principal o *app.py*. A continuación, se muestra cómo se han implementado las diferentes funciones mencionadas dentro de la clase Transform.

```
transform.py X
src > transform.py > Transform > classify
1 import plotly.express as px
2 from extract import Extract
3
4 # creamos la instancia de la clase Extract
5 extract = Extract()
6
7 class Transform():
8     # Función que guarda todos los valores de una key específica en una lista
9     def values_list(self, url, key) -> list:
10         # guardamos los datos del diccionario que queremos en data
11         data = extract.extract_paginated_data(url)
12         # Extraemos todos los valores y los guardamos en una lista
13         values_list = []
14         for values in data:
15             values_list.append(values[key])
16         return values_list
17
18     # Función que genera una tupla con dos listas con los top n elementos
19     def top_n(self, my_list, key_1, key_2, n, m) -> tuple:
20         # lista con el nombre de todos los elementos en la lista elem_1
21         elem_1 = [elem[key_1] for elem in my_list]
22         # lista con los key_2
23         # si el value es 'unknown' lo sustituimos por 0
24         elem_2_str = [elem[key_2] if elem[key_2] != 'unknown' else 0 for elem in my_list]
25         # convertimos de str a int
26         elem_2_int = list(map(int, elem_2_str))
27         # ordenamos las listas en orden descendente
28         elem_1 = [x for _, x in sorted(zip(elem_2_int, elem_1), reverse=True)]
29         elem_2_int = sorted(elem_2_int, reverse=True)
30         # top n elementos
31         top_n_elem_1 = elem_1[n:m]
32         top_n_elem_2 = elem_2_int[n:m]
33         return top_n_elem_1, top_n_elem_2
34
35
36
37
38
39
40
41
42
43
44
45
46
47
48
49
50
51
52
53
54
55
56
57
58
59
60
61
62
63
64
65
66
67
68
69
70
71
72
73
74
75
76
77
78
79
80
81
82
83
84
85
86
87
88
89
90
91
92
93
94
95
96
97
98
99
100
101
102
103
104
105
106
107
108
109
110
111
112
113
114
115
116
117
118
119
120
121
122
123
124
125
126
127
128
129
130
131
132
133
134
135
136
137
138
139
140
141
142
143
144
145
146
147
148
149
150
151
152
153
154
155
156
157
158
159
160
161
162
163
164
165
166
167
168
169
170
171
172
173
174
175
176
177
178
179
180
181
182
183
184
185
186
187
188
189
190
191
192
193
194
195
196
197
198
199
200
201
202
203
204
205
206
207
208
209
210
211
212
213
214
215
216
217
218
219
220
221
222
223
224
225
226
227
228
229
230
231
232
233
234
235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251
252
253
254
255
256
257
258
259
260
261
262
263
264
265
266
267
268
269
270
271
272
273
274
275
276
277
278
279
280
281
282
283
284
285
286
287
288
289
290
291
292
293
294
295
296
297
298
299
300
301
302
303
304
305
306
307
308
309
310
311
312
313
314
315
316
317
318
319
320
321
322
323
324
325
326
327
328
329
330
331
332
333
334
335
336
337
338
339
340
341
342
343
344
345
346
347
348
349
350
351
352
353
354
355
356
357
358
359
360
361
362
363
364
365
366
367
368
369
370
371
372
373
374
375
376
377
378
379
380
381
382
383
384
385
386
387
388
389
390
391
392
393
394
395
396
397
398
399
400
401
402
403
404
405
406
407
408
409
410
411
412
413
414
415
416
417
418
419
420
421
422
423
424
425
426
427
428
429
430
431
432
433
434
435
436
437
438
439
440
441
442
443
444
445
446
447
448
449
450
451
452
453
454
455
456
457
458
459
460
461
462
463
464
465
466
467
468
469
470
471
472
473
474
475
476
477
478
479
480
481
482
483
484
485
486
487
488
489
490
491
492
493
494
495
496
497
498
499
500
501
502
503
504
505
506
507
508
509
510
511
512
513
514
515
516
517
518
519
520
521
522
523
524
525
526
527
528
529
530
531
532
533
534
535
536
537
538
539
540
541
542
543
544
545
546
547
548
549
550
551
552
553
554
555
556
557
558
559
560
561
562
563
564
565
566
567
568
569
570
571
572
573
574
575
576
577
578
579
580
581
582
583
584
585
586
587
588
589
590
591
592
593
594
595
596
597
598
599
600
601
602
603
604
605
606
607
608
609
610
611
612
613
614
615
616
617
618
619
620
621
622
623
624
625
626
627
628
629
630
631
632
633
634
635
636
637
638
639
640
641
642
643
644
645
646
647
648
649
650
651
652
653
654
655
656
657
658
659
660
661
662
663
664
665
666
667
668
669
670
671
672
673
674
675
676
677
678
679
680
681
682
683
684
685
686
687
688
689
690
691
692
693
694
695
696
697
698
699
700
701
702
703
704
705
706
707
708
709
710
711
712
713
714
715
716
717
718
719
720
721
722
723
724
725
726
727
728
729
730
731
732
733
734
735
736
737
738
739
740
741
742
743
744
745
746
747
748
749
750
751
752
753
754
755
756
757
758
759
760
761
762
763
764
765
766
767
768
769
770
771
772
773
774
775
776
777
778
779
780
781
782
783
784
785
786
787
788
789
790
791
792
793
794
795
796
797
798
799
800
801
802
803
804
805
806
807
808
809
810
811
812
813
814
815
816
817
818
819
820
821
822
823
824
825
826
827
828
829
830
831
832
833
834
835
836
837
838
839
840
841
842
843
844
845
846
847
848
849
850
851
852
853
854
855
856
857
858
859
860
861
862
863
864
865
866
867
868
869
870
871
872
873
874
875
876
877
878
879
880
881
882
883
884
885
886
887
888
889
890
891
892
893
894
895
896
897
898
899
900
901
902
903
904
905
906
907
908
909
910
911
912
913
914
915
916
917
918
919
920
921
922
923
924
925
926
927
928
929
930
931
932
933
934
935
936
937
938
939
940
941
942
943
944
945
946
947
948
949
950
951
952
953
954
955
956
957
958
959
960
961
962
963
964
965
966
967
968
969
970
971
972
973
974
975
976
977
978
979
980
981
982
983
984
985
986
987
988
989
990
991
992
993
994
995
996
997
998
999
1000
1001
1002
1003
1004
1005
1006
1007
1008
1009
1010
1011
1012
1013
1014
1015
1016
1017
1018
1019
1020
1021
1022
1023
1024
1025
1026
1027
1028
1029
1030
1031
1032
1033
1034
1035
1036
1037
1038
1039
1040
1041
1042
1043
1044
1045
1046
1047
1048
1049
1050
1051
1052
1053
1054
1055
1056
1057
1058
1059
1060
1061
1062
1063
1064
1065
1066
1067
1068
1069
1070
1071
1072
1073
1074
1075
1076
1077
1078
1079
1080
1081
1082
1083
1084
1085
1086
1087
1088
1089
1090
1091
1092
1093
1094
1095
1096
1097
1098
1099
1100
1101
1102
1103
1104
1105
1106
1107
1108
1109
1110
1111
1112
1113
1114
1115
1116
1117
1118
1119
1120
1121
1122
1123
1124
1125
1126
1127
1128
1129
1130
1131
1132
1133
1134
1135
1136
1137
1138
1139
1140
1141
1142
1143
1144
1145
1146
1147
1148
1149
1150
1151
1152
1153
1154
1155
1156
1157
1158
1159
1160
1161
1162
1163
1164
1165
1166
1167
1168
1169
1170
1171
1172
1173
1174
1175
1176
1177
1178
1179
1180
1181
1182
1183
1184
1185
1186
1187
1188
1189
1190
1191
1192
1193
1194
1195
1196
1197
1198
1199
1200
1201
1202
1203
1204
1205
1206
1207
1208
1209
1210
1211
1212
1213
1214
1215
1216
1217
1218
1219
1220
1221
1222
1223
1224
1225
1226
1227
1228
1229
1230
1231
1232
1233
1234
1235
1236
1237
1238
1239
1240
1241
1242
1243
1244
1245
1246
1247
1248
1249
1250
1251
1252
1253
1254
1255
1256
1257
1258
1259
1260
1261
1262
1263
1264
1265
1266
1267
1268
1269
1270
1271
1272
1273
1274
1275
1276
1277
1278
1279
1280
1281
1282
1283
1284
1285
1286
1287
1288
1289
1290
1291
1292
1293
1294
1295
1296
1297
1298
1299
1300
1301
1302
1303
1304
1305
1306
1307
1308
1309
1310
1311
1312
1313
1314
1315
1316
1317
1318
1319
1320
1321
1322
1323
1324
1325
1326
1327
1328
1329
1330
1331
1332
1333
1334
1335
1336
1337
1338
1339
1340
1341
1342
1343
1344
1345
1346
1347
1348
1349
1350
1351
1352
1353
1354
1355
1356
1357
1358
1359
1360
1361
1362
1363
1364
1365
1366
1367
1368
1369
1370
1371
1372
1373
1374
1375
1376
1377
1378
1379
1380
1381
1382
1383
1384
1385
1386
1387
1388
1389
1390
1391
1392
1393
1394
1395
1396
1397
1398
1399
1400
1401
1402
1403
1404
1405
1406
1407
1408
1409
1410
1411
1412
1413
1414
1415
1416
1417
1418
1419
1420
1421
1422
1423
1424
1425
1426
1427
1428
1429
1430
1431
1432
1433
1434
1435
1436
1437
1438
1439
1440
1441
1442
1443
1444
1445
1446
1447
1448
1449
1450
1451
1452
1453
1454
1455
1456
1457
1458
1459
1460
1461
1462
1463
1464
1465
1466
1467
1468
1469
1470
1471
1472
1473
1474
1475
1476
1477
1478
1479
1480
1481
1482
1483
1484
1485
1486
1487
1488
1489
1490
1491
1492
1493
1494
1495
1496
1497
1498
1499
1500
1501
1502
1503
1504
1505
1506
1507
1508
1509
1510
1511
1512
1513
1514
1515
1516
1517
1518
1519
1520
1521
1522
1523
1524
1525
1526
1527
1528
1529
1530
1531
1532
1533
1534
1535
1536
1537
1538
1539
1540
1541
1542
1543
1544
1545
1546
1547
1548
1549
1550
1551
1552
1553
1554
1555
1556
1557
1558
1559
1560
1561
1562
1563
1564
1565
1566
1567
1568
1569
1570
1571
1572
1573
1574
1575
1576
1577
1578
1579
1580
1581
1582
1583
1584
1585
1586
1587
1588
1589
1590
1591
1592
1593
1594
1595
1596
1597
1598
1599
1600
1601
1602
1603
1604
1605
1606
1607
1608
1609
1610
1611
1612
1613
1614
1615
1616
1617
1618
1619
1620
1621
1622
1623
1624
1625
1626
1627
1628
1629
1630
1631
1632
1633
1634
1635
1636
1637
1638
1639
1640
1641
1642
1643
1644
1645
1646
1647
1648
1649
1650
1651
1652
1653
1654
1655
1656
1657
1658
1659
1660
1661
1662
1663
1664
1665
1666
1667
1668
1669
1670
1671
1672
1673
1674
1675
1676
1677
1678
1679
1680
1681
1682
1683
1684
1685
1686
1687
1688
1689
1690
1691
1692
1693
1694
1695
1696
1697
1698
1699
1700
1701
1702
1703
1704
1705
1706
1707
1708
1709
1710
1711
1712
1713
1714
1715
1716
1717
1718
1719
1720
1721
1722
1723
1724
1725
1726
1727
1728
1729
1730
1731
1732
1733
1734
1735
1736
1737
1738
1739
1740
1741
1742
1743
1744
1745
1746
1747
1748
1749
1750
1751
1752
1753
1754
1755
1756
1757
1758
1759
1760
1761
1762
1763
1764
1765
1766
1767
1768
1769
1770
1771
1772
1773
1774
1775
1776
1777
1778
1779
1780
1781
1782
1783
1784
1785
1786
1787
1788
1789
1790
1791
1792
1793
1794
1795
1796
1797
1798
1799
1800
1801
1802
1803
1804
1805
1806
1807
1808
1809
1810
1811
1812
1813
1814
1815
1816
1817
1818
1819
1820
1821
1822
1823
1824
1825
1826
1827
1828
1829
1830
1831
1832
1833
1834
1835
1836
1837
1838
1839
1840
1841
1842
1843
1844
1845
1846
1847
1848
1849
1850
1851
1852
1853
1854
1855
1856
1857
1858
1859
1860
1861
1862
1863
1864
1865
1866
1867
1868
1869
1870
1871
1872
1873
1874
1875
1876
1877
1878
1879
1880
1881
1882
1883
1884
1885
1886
1887
1888
1889
1890
1891
1892
1893
1894
1895
1896
1897
1898
1899
1900
1901
1902
1903
1904
1905
1906
1907
1908
1909
1910
1911
1912
1913
1914
1915
1916
1917
1918
1919
1920
1921
1922
1923
1924
1925
1926
1927
1928
1929
1930
1931
1932
1933
1934
1935
1936
1937
1938
1939
1940
1941
1942
1943
1944
1945
1946
1947
1948
1949
1950
1951
1952
1953
1954
1955
1956
1957
1958
1959
1960
1961
1962
1963
1964
1965
1966
1967
1968
1969
1970
1971
1972
1973
1974
1975
1976
1977
1978
1979
1980
1981
1982
1983
1984
1985
1986
1987
1988
1989
1990
1991
1992
1993
1994
1995
1996
1997
1998
1999
2000
2001
2002
2003
2004
2005
2006
2007
2008
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018
2019
2020
2021
2022
2023
2024
2025
2026
2027
2028
2029
2030
2031
2032
2033
2034
2035
2036
2037
2038
2039
2040
2041
2042
2043
2044
2045
2046
2047
2048
2049
2050
2051
2052
2053
2054
2055
2056
2057
2058
2059
2060
2061
2062
2063
2064
2065
2066
2067
2068
2069
2070
2071
2072
2073
2074
2075
2076
2077
2078
2079
2080
2081
2082
2083
2084
2085
2086
2087
2088
2089
2090
2091
2092
2093
2094
2095
2096
2097
2098
2099
2100
2101
2102
2103
2104
2105
2106
2107
2108
2109
2110
2111
2112
2113
2114
2115
2116
2117
2118
2119
2120
2121
2122
2123
2124
2125
2126
2127
2128
2129
2130
2131
2132
2133
2134
2135
2136
2137
2138
2139
2140
2141
2142
2143
2144
2145
2146
2147
2148
2149
2150
2151
2152
2153
2154
2155
2156
2157
2158
2159
2160
2161
2162
2163
2164
2165
2166
2167
2168
2169
2170
2171
2172
2173
2174
2175
2176
2177
2178
2179
2180
2181
2182
2183
2184
2185
2186
2187
2188
2189
2190
2191
2192
2193
2194
2195
2196
2197
2198
2199
2200
2201
2202
2203
2204
2205
2206
2207
2208
2209
2210
2211
2212
2213
2214
2215
2216
2217
2218
2219
2220
2221
2222
2223
2224
2225
2226
2227
2228
2229
2230
2231
2232
2233
2234
2235
2236
2237
2238
2239
2240
2241
2242
2243
2244
2245
2246
2247
2248
2249
2250
2251
2252
2253
2254
2255
2256
2257
2258
2259
2260
2261
2262
2263
2264
2265
2266
2267
2268
2269
2270
2271
2272
2273
2274
2275
2276
2277
2278
2279
2280
2281
2282
2283
2284
2285
2286
2287
2288
2289
2290
2291
2292
2293
2294
2295
2296
2297
2298
2299
2300
2301
2302
2303
2304
2305
2306
2307
2308
2309
2310
2311
2312
2313
2314
2315
2316
2317
2318
2319
2320
2321
2322
2323
2324
2325
2326
2327
2328
2329
2330
2331
2332
2333
2334
2335
2336
2337
2338
2339
2340
2341
2342
2343
2344
2345
2346
2347
2348
2349
2350
2351
2352
2353
2354
2355
2356
2357
2358
2359
2360
2361
2362
2363
2364
2365
2366
2367
2368
2369
2370
2371
2372
2373
2374
2375
2376
2377
2378
2379
2380
2381
2382
2383
2384
2385
2386
2387
2388
2389
2390
2391
2392
2393
2394
2395
2396
2397
2398
2399
2400
2401
2402
2403
2404
2405
2406
2407
2408
2409
2410
2411
2412
2413
2414
2415
2416
2417
2418
2419
2420
2421
2422
2423
2424
2425
2426
2427
2428
2429
2430
2431
2432
2433
2434
2435
2436
2437
2438
2439
2440
2441
2442
2443
2444
2445
2446
2447
2448
2449
2450
2451
2452
2453
2454
2455
2456
2457
2458
2459
2460
2461
2462
2463
2464
2465
2466
2467
2468
2469
2470
2471
2472
2473
2474
2475
2476
2477
2478
2479
2480
2481
2482
2483
2484
2485
2486
2487
2488
2489
2490
2491
2492
2493
2494
2495
2496
2497
2498
2499
2500
2501
2502
2503
2504
2505
2506
2507
2508
2509
2510
2511
2512
2513
2514
2515
2516
2517
25
```

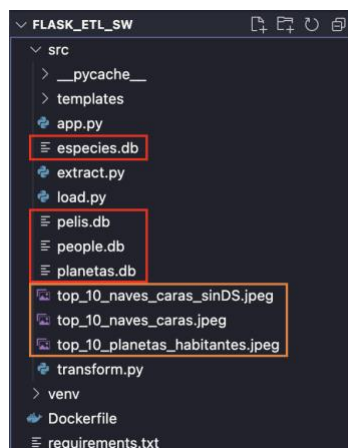
Carga de datos (Load)

Los resultados obtenidos se han almacenado de dos maneras distintas: en bases de datos SQL para los datos estructurados y en formato .jpeg para los gráficos o *plots*.

En la siguiente imagen se muestra el código que permite cargar los datos. La primera función, *save_plot()*, permite guardar gráficos, especificando el formato (jpeg, png, etc) y en qué carpeta los queremos guardar. La segunda función, *save_people_db()*, guarda los nombres de los personajes en la base de datos SQL *people.db*. Se han creado 3 funciones más, muy similares a *save_people_db()*, que permiten guardar en bases de datos SQL el nombre de los planetas, el título de las películas, y el nombre y clasificación de cada especie.

```
load.py x
src > load.py > Load > save_species_db
1 import plotly.io as pio
2 from sqlalchemy import create_engine, Column, Integer, String
3 from sqlalchemy.ext.declarative import declarative_base
4 from sqlalchemy.orm import sessionmaker
5
6 class Load():
7     # Función que guarda gráficos en el formato deseado (jpeg, png, etc) en la carpeta deseada
8     def save_plot(self, fig, file, format) -> None:
9         # guarda el plot en el formato deseado
10        pio.write_image(fig, file, format=format)
11
12    # Función que guarda los nombres de los personajes en la base de datos
13    def save_people_db(self, data) -> None:
14        # set up the database
15        engine = create_engine('sqlite:///people.db')
16        Base = declarative_base()
17
18        class Person(Base):
19            __tablename__ = 'people'
20
21            id = Column(Integer, primary_key=True)
22            name = Column(String)
23
24        Base.metadata.create_all(engine)
25
26        # create a session to interact with the database
27        Session = sessionmaker(bind=engine)
28        session = Session()
29
30        # save each person's name to the database
31        for elem in data:
32            p = Person(name=elem)
33            session.add(p)
34            session.commit()
35        session.close()
```

Una vez el usuario accede a los diferentes enlaces de la web, los resultados se descargan y se guardan en la propia carpeta del proyecto.



Podemos ver, por ejemplo, como queda la base de datos de las especies:

SQLite

SQL 1 / 1 1 - 37 of 37

id	name	classification
1	Human	mammal
2	Droid	artificial
3	Wookiee	mammal
4	Rodian	sentient
5	Hutt	gastropod
6	Yoda's species	mammal
7	Trandoshan	reptile
8	Mon Calamari	amphibian

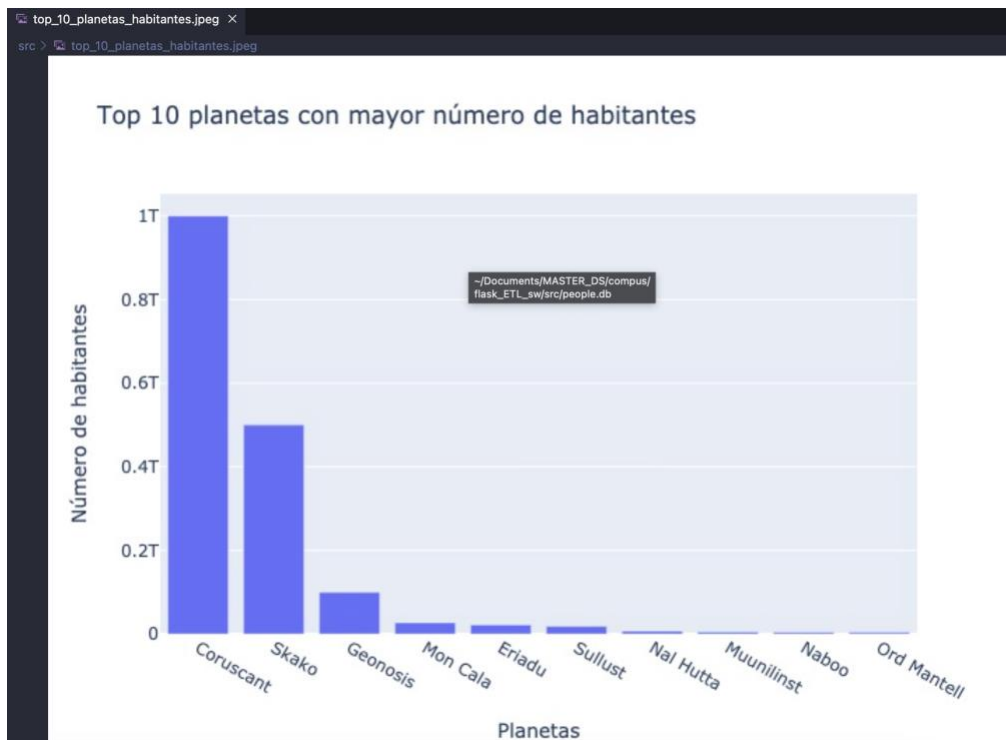
SQLITE EXPLORER

especies.db

especies

- id : integer
- name : varchar
- classification : varchar

A continuación, se muestra uno de los gráficos generados en formato .jpeg.



Programa principal (app.py)

En el programa principal o *app.py*, se han creado las instancias de las clases Extract, Transform y Load, se han definido un conjunto de variables que contienen las URLs de las diferentes APIs de Star Wars, y se han definido las distintas rutas que tiene nuestra aplicación:

- home o índice
- personajes
- pelis
- planetas
- plots
- starships
- especies

A continuación, se muestra el código del archivo *app.py*, por si es de interés consultarlo.

```
app.py x
src > app.py > ...
1  from flask import Flask, render_template
2  from extract import Extract
3  from transform import Transform
4  from load import Load
5  import plotly
6  import json
7
8  # creamos el objeto app como una instancia de la clase Flask importada del paquete flask
9  app = Flask(__name__)
10
11 # creamos las instancias de las clases Extract, Transform y Load
12 extract = Extract()
13 transform = Transform()
14 load = Load()
15
16 # APIs
17 people_url = 'https://swapi.dev/api/people/'
18 planets_url = 'https://swapi.dev/api/planets/'
19 films_url = 'https://swapi.dev/api/films/'
20 species_url = 'https://swapi.dev/api/species/'
21 vehicles_url = 'https://swapi.dev/api/vehicles/'
22 starships_url = 'https://swapi.dev/api/starships/'
23
24 # Creamos las rutas
25 # índice con los enlaces
26 @app.route('/', methods=['GET'])
27 def index():
28     return render_template('index.html')
29
30 # personajes
31 @app.route('/personajes', methods=['GET'])
32 def people_name():
33     people_names = transform.values_list(people_url, 'name')
34     # guardamos los nombres de los personajes en la base de datos
35     load.save_people_db(people_names)
36     return render_template('people.html', data=people_names)
37
38 # películas
39 @app.route('/pelis', methods=['GET'])
40 def films_title():
41     films_title = transform.values_list(films_url, 'title')
42     # guardamos los títulos de las pelis en la base de datos
43     load.save_films_db(films_title)
44     return render_template('films.html', data=films_title)
45
```

```

38 # películas
39 @app.route('/pelis', methods=['GET'])
40 def films_title():
41     films_title = transform.values_list(films_url, 'title')
42     # guardamos los títulos de las pelis en la base de datos
43     load.save_films_db(films_title)
44     return render_template('films.html', data=films_title)
45
46 # planetas
47 @app.route('/planetas', methods=['GET'])
48 def planets_name():
49     planets_name = transform.values_list(planets_url, 'name')
50     # guardamos los planetas en la base de datos
51     load.save_planets_db(planets_name)
52     return render_template('planets.html', data=planets_name)
53
54 # gráfico 10 planetas con mayor número de habitantes
55 @app.route('/plots', methods=['GET'])
56 def planets_population():
57     planets = extract.extract_paginated_data(planets_url)
58     # listas con el nombre y la población de los 10 planetas más poblados
59     top_10_planet_names, top_10_planet_population = transform.top_n(planets, 'name', 'population', 0, 10)
60     # creamos el barplot con plotly
61     fig1 = transform.create_bar_chart(x = top_10_planet_names, y = top_10_planet_population,
62                                     title="Top 10 planetas con mayor número de habitantes",
63                                     xaxis_title="Planetas",
64                                     yaxis_title="Número de habitantes")
65     # guardamos el plot en formato jpeg en el directorio de trabajo
66     load.save_plot(fig1, 'top_10_planetas_habitantes.jpeg', 'jpeg')
67     # convertimos el barplot a JSON
68     graph1JSON = json.dumps(fig1, cls = plotly.utils.PlotlyJSONEncoder)
69     # renderizamos el HTML template con el barplot JSON
70     return render_template("plots.html", graph1JSON = graph1JSON)
71
72 # gráficos con las 10 naves espaciales más caras
73 @app.route('/starships', methods=['GET'])
74 def starships_price():
75     starships = extract.extract_paginated_data(starships_url)
76     # listas con el nombre y el precio
77     top_10_starship_names, top_10_starship_prices = transform.top_n(starships, 'name', 'cost_in_credits', 0, 10)
78     top_10_starship_names_noDS, top_10_starship_prices_noDS = transform.top_n(starships, 'name', 'cost_in_credits', 1, 11)
79     # creamos los barplots con plotly
80     fig2 = transform.create_bar_chart(x = top_10_starship_names, y = top_10_starship_prices,
81                                     title="Top 10 naves espaciales más caras",
82                                     xaxis_title="Naves espaciales",
83                                     yaxis_title="Coste en créditos")
84     fig3 = transform.create_bar_chart(x = top_10_starship_names_noDS, y = top_10_starship_prices_noDS,
85                                     title="Top 10 naves espaciales más caras sin contar la Estrella de la Muerte",
86                                     xaxis_title="Naves espaciales",
87                                     yaxis_title="Coste en créditos")
88     # guardamos el plot en formato jpeg en el directorio de trabajo
89     load.save_plot(fig2, 'top_10_naves_caras.jpeg', 'jpeg')
90     load.save_plot(fig3, 'top_10_naves_caras_sinDS.jpeg', 'jpeg')
91     # convertimos el barplot a JSON
92     graph2JSON = json.dumps(fig2, cls = plotly.utils.PlotlyJSONEncoder)
93     graph3JSON = json.dumps(fig3, cls = plotly.utils.PlotlyJSONEncoder)
94     # renderizamos el HTML template con el barplot JSON
95     return render_template("starships_plot.html", graph2JSON = graph2JSON, graph3JSON = graph3JSON)
96
97 # especies: nombre y clasificación
98 @app.route('/especies', methods=['GET'])
99 def species_classification():
100     species = extract.extract_paginated_data(species_url)
101     species_classif = transform.classify(species, 'name', 'classification')
102     # guardamos las especies y su clasificación en la base de datos
103     load.save_species_db(species_classif)
104     return render_template("species_table.html", data=species_classif)
105
106
107 # se ejecutará solo si este archivo se está ejecutando como el archivo que arranca la aplicación
108 if __name__ == '__main__':
109     # llamamos al método app.run() para iniciar la aplicación Flask y hacerla accesible en el host y puerto especificados
110     app.run(host="0.0.0.0", port=4000, debug=True)

```

Contenerización de la aplicación con Docker

Una vez hemos terminado la aplicación y funciona correctamente, la colocaremos en un contenedor utilizando Docker. Este contenedor englobará toda la aplicación: el código y los programas que necesita para funcionar. De esta manera, cuando movamos el contenedor a otro ordenador, va a venir con todos los programas ya instalados.

Dockerfile

Para ello, lo primero que haremos será crear un archivo Dockerfile dentro de nuestra aplicación. El archivo Dockerfile nos permite crear imágenes para crear posteriormente contenedores. Una imagen Docker es un archivo que contiene todos los componentes y dependencias necesarias para ejecutar una aplicación o servicio específico en un contenedor Docker.

En el Dockerfile se especifica paso a paso lo que necesita la aplicación para funcionar en cualquier sistema. A continuación, se muestra el archivo Dockerfile para nuestra aplicación.

```
Dockerfile > ...
1  FROM python:3.11-slim
2
3  # Update the package repository and install dependencies
4  RUN apt-get update && \
5      apt-get install -y build-essential
6
7  # Set the working directory to /app
8  WORKDIR /app
9
10 # Copy the current directory contents into the container at /app
11 COPY . /app
12
13 # Install the dependencies
14 RUN pip3 install -r requirements.txt
15
16 # Run app.py when the container launches
17 CMD ["python3", "src/app.py"]
```

Consta de 6 pasos:

1. La aplicación necesita Python para funcionar. Hemos escogido como imagen base python:3.11-slim, basada en Debian GNU/Linux. Esta imagen existente en DockerHub nos servirá como punto de partida para construir nuestra propia imagen.
2. A continuación, actualizamos el listado de paquetes e instalamos las dependencias esenciales.
3. Establecemos que nuestro directorio de trabajo sea /app.
4. Todos los archivos y carpetas de nuestra aplicación los copiamos en la carpeta de nuestro directorio de trabajo: /app.
5. Instalamos las dependencias especificadas en el archivo requirements.txt, es decir, lo que necesita nuestra aplicación para que funcione en cualquier sistema.
6. Ejecutamos la aplicación. Ejecutamos python3 y desde la carpeta src, ejecutamos el archivo app.py.

Generación de la imagen

Una vez creado el Dockerfile, generamos la imagen con el siguiente comando: `docker build -t flaskapp .`

```
└─ docker build -t flaskapp .
[+] Building 57.1s (10/10) FINISHED
=> [internal] load build definition from Dockerfile
=> => transferring dockerfile: 793B
=> [internal] load .dockerignore
=> => transferring context: 2B
=> [internal] load metadata for docker.io/library/python:3.11-slim
=> [1/5] FROM docker.io/library/python:3.11-slim@sha256:555dcc94587b4101de48664b45b19f17e099a3ab236dec629791f366e2f2e83c
=> [internal] load build context
=> => transferring context: 5.32MB
=> CACHED [2/5] RUN apt-get update && apt-get install -y build-essential
=> [3/5] WORKDIR /app
=> [4/5] COPY . /app
=> [5/5] RUN pip3 install -r requirements.txt
=> exporting to image
=> => exporting layers
=> => writing image sha256:5a39439268919c2702a2f5389518a2bbee7f4ced8d7975891c19579507fb2ec1
=> => naming to docker.io/library/flaskapp
```

Podemos ver como se ejecutan cada uno de los pasos especificados en el Dockerfile. Ahora la imagen *flaskapp* ya se ha generado.

```
└─ docker images
REPOSITORY          TAG          IMAGE ID          CREATED          SIZE
flaskapp             latest       5a3943926891     10 seconds ago  1.55GB
```

Creación del volumen

A continuación, creamos el volumen llamado *flaskapp_volume*. Esto permitirá que, aunque borremos el contenedor, lo de dentro de *flaskapp_volume* no se borre. Además, podremos descargar localmente todo lo que esté dentro del volumen.

```
└─ docker volume create flaskapp_volume
flaskapp_volume

└─ docker volume ls
DRIVER    VOLUME NAME
local     flaskapp_volume

└─ docker volume inspect flaskapp_volume
[
  {
    "CreatedAt": "2022-12-10T20:59:57Z",
    "Driver": "local",
    "Labels": {},
    "Mountpoint": "/var/lib/docker/volumes/flaskapp_volume/_data",
    "Name": "flaskapp_volume",
    "Options": {},
    "Scope": "local"
  }
]
```

Ejecución de la imagen en un contenedor

Ejecutamos la imagen *flaskapp* en un contenedor con el siguiente comando:

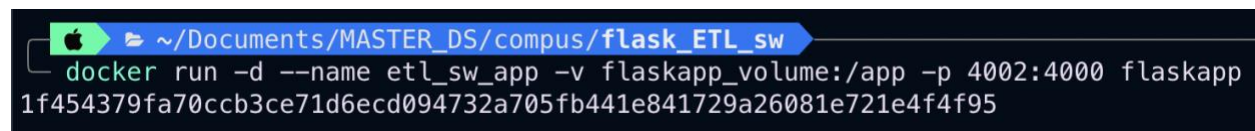
```
docker run -d --name etl_sw_app -v flaskapp_volume:/app -p 4002:4000 flaskapp
```

El comando **docker run** se utiliza para ejecutar una imagen Docker en un contenedor Docker. El comando anterior ejecuta una imagen Docker llamada *flaskapp* en un contenedor llamado *etl_sw_app*, en modo *detached* (**-d**), lo que significa que el contenedor se ejecutará en segundo plano.

La **-v** especifica un volumen para montar en el contenedor. En este caso, el volumen *flaskapp_volume* se monta en la ruta **/app** del contenedor. Esto significa que cualquier dato escrito en la ruta **/app** en el contenedor será escrito en el volumen *flaskapp_volume* en la máquina anfitriona, y viceversa. Esto permite compartir datos entre el contenedor y la máquina anfitriona.

El indicador **-p** especifica la asignación de puertos para el contenedor. En este caso, el puerto **4000** del contenedor está mapeado al puerto **4002** de la máquina anfitriona, lo que significa que cualquier tráfico al puerto 4002 de la máquina anfitriona será reenviado al puerto 4000 del contenedor. Esto permite que se pueda acceder a la aplicación que se ejecuta en el contenedor desde la máquina host.

Por tanto, cuando se ejecuta el comando *docker run*, se crea un nuevo contenedor Docker a partir de la imagen *flaskapp*, se monta el volumen *flaskapp_volume* en la ruta **/app** y se expone el puerto 4000 del contenedor en el puerto 4002 de la máquina host. A continuación, el contenedor ejecuta la imagen *flaskapp*, que inicia la aplicación dentro del contenedor.

A terminal window with a dark background. The prompt is a green circle with an Apple logo. The path is ~/Documents/MASTER_DS/compus/flask_ETL_sw. The command is docker run -d --name etl_sw_app -v flaskapp_volume:/app -p 4002:4000 flaskapp. The output is a long alphanumeric string: 1f454379fa70ccb3ce71d6ecd094732a705fb441e841729a26081e721e4f4f95.

```
~/Documents/MASTER_DS/compus/flask_ETL_sw  
docker run -d --name etl_sw_app -v flaskapp_volume:/app -p 4002:4000 flaskapp  
1f454379fa70ccb3ce71d6ecd094732a705fb441e841729a26081e721e4f4f95
```

Copiando el enlace que nos devuelve la ejecución del comando anterior o simplemente escribiendo *localhost:4002* en el navegador web, se nos abre la aplicación web. Las siguientes imágenes muestran la aplicación web creada. Cada enlace nos mostrará un resultado de nuestra ETL.

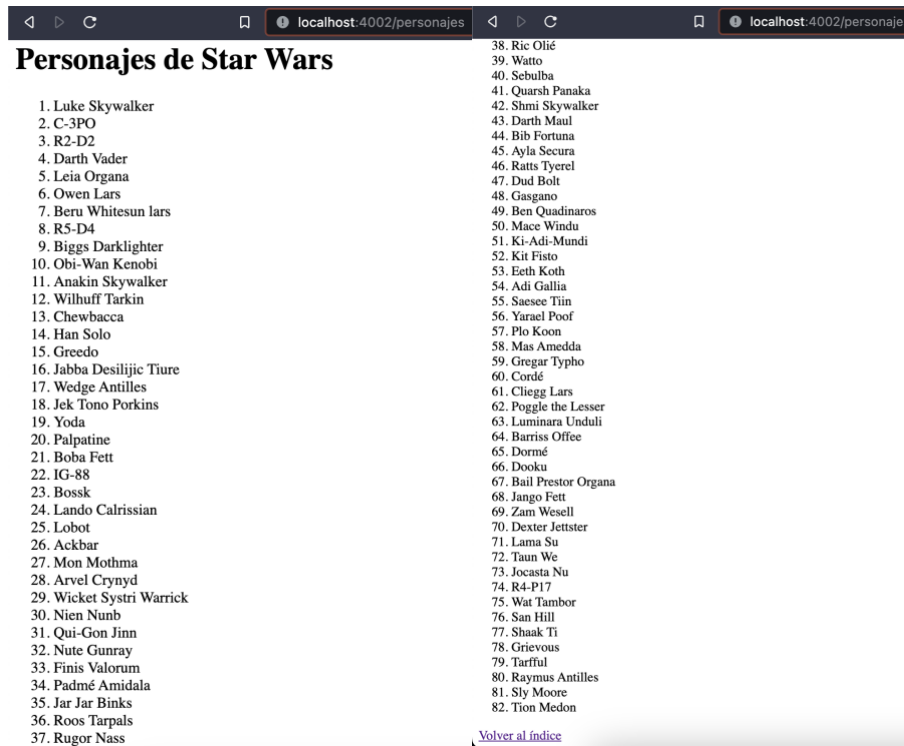


STAR WARS

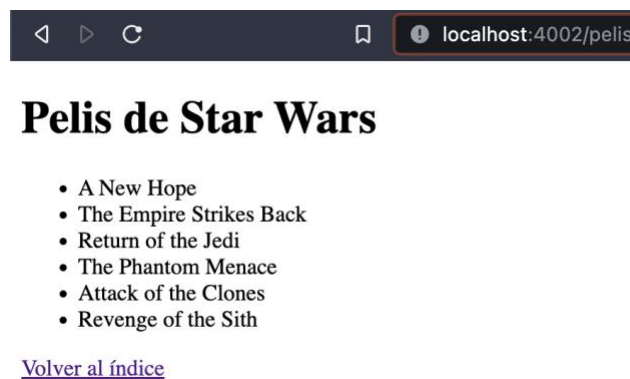
- [Todos los personajes de Star Wars](#)
- [Pelis de Star Wars por orden de estreno](#)
- [Todos los planetas de Star Wars](#)
- [Top 10 planetas con mayor población](#)
- [Top 10 naves espaciales más caras](#)
- [Especies: nombre y clasificación](#)

Veamos que nos muestra cada enlace.

- [Todos los personajes de Star Wars](#)



- [Pelis de Star Wars por orden de estreno](#)



- [Todos los planetas de Star Wars](#)

localhost:4002/planetas

Planetas de Star Wars

1. Tatooine

2. Alderaan

3. Yavin IV

4. Hoth

5. Dagobah

6. Bespin

7. Endor

8. Naboo

9. Coruscant

10. Kamino

11. Geonosis

12. Utapau

13. Mustafar

14. Kashyyyk

15. Polis Massa

16. Mygeeto

17. Felucia

18. Cato Neimoidia

19. Saleucami

20. Stewjon

21. Eriadu

22. Corellia

23. Rodia

24. Nal Hutta

25. Dantooine

26. Bestine IV

27. Ord Mantell

28. unknown

29. Trandosha

30. Socorro

31. Mon Cala

32. Chandrila

33. Sullust

34. Toydaria

35. Malastare

36. Dathomir

37. Ryloth

38. Aleen Minor

39. Vulper

40. Troiken

41. Tund

42. Haruun Kal

43. Cerea

44. Glee Anselm

45. Iridonia

46. Tholoth

47. Iktotch

48. Quermia

49. Dorin

50. Champala

51. Mirial

52. Serenno

53. Concord Dawn

54. Zolan

55. Ojom

56. Skako

57. Muunilinst

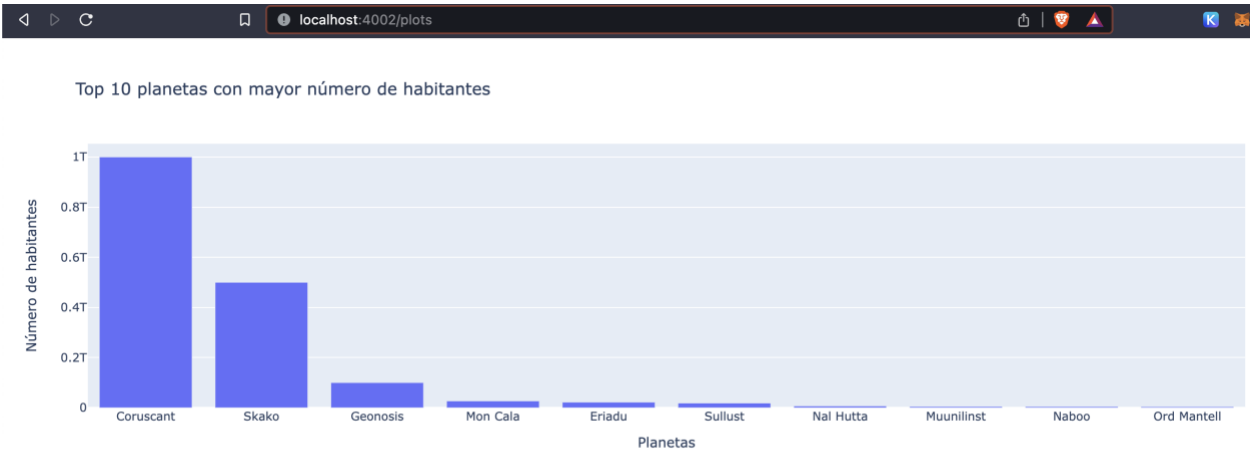
58. Shili

59. Kalee

60. Umbara

[Volver al índice](#)

- [Top 10 planetas con mayor población](#)




[Volver al índice](#)


- [Top 10 naves espaciales más caras](#)

localhost:4002/starships

Top 10 naves espaciales más caras



Top 10 naves espaciales más caras sin contar la Estrella de la Muerte



[Volver al índice](#)

- [Especies: nombre y clasificación](#)



Nombre y clasificación de las especies

Nombre	Clasificación
Human	mammal
Droid	artificial
Wookie	mammal
Rodian	sentient
Hutt	gastropod
Yoda's species	mammal
Trandoshan	reptile
Mon Calamari	amphibian
Ewok	mammal
Sullustan	mammal
Neimodian	unknown
Gungan	amphibian
Toydarian	mammal
Dug	mammal
Twi'lek	mammals
Aleena	reptile
Vulptereen	unknown
Xexto	unknown
Toong	unknown
Cerean	mammal
Nautolan	amphibian
Zabrak	mammal
Tholothian	mammal
Iktotchi	unknown
Quermian	mammal
Kel Dor	unknown
Chagrian	amphibian
Geonosian	insectoid

Mirialan	mammal
Clawdite	reptilian
Besalisk	amphibian
Kaminoan	amphibian
Skakoan	mammal
Muun	mammal
Togruta	mammal
Kaleesh	reptile
Pau'an	mammal

[Volver al índice](#)

Podemos ver que todo funciona correctamente.

Comprobaciones finales

Comprobamos que el *path* en el que está corriendo el contenedor sea */app*.

```
~/Documents/MASTER_DS/compus/flask_ETL_sw
docker exec 1f454379fa70 pwd
/app
```

Antes de que el usuario de la aplicación acceda a los enlaces de la web, no se deben haber generado ningún gráfico ni base de datos. Lo comprobamos mirando el contenido de lo que está corriendo en el contenedor. Para ello usamos el comando *docker exec container_id ls*. Este comando se ejecuta dentro del contenedor, no en mi máquina local.

```
~/Documents/MASTER_DS/compus/flask_ETL_sw
docker exec 1f454379fa70 ls
Dockerfile
requirements.txt
src
venv
```

- Podemos ver que antes de acceder a los enlaces no se ha generado ningún gráfico ni base de datos.

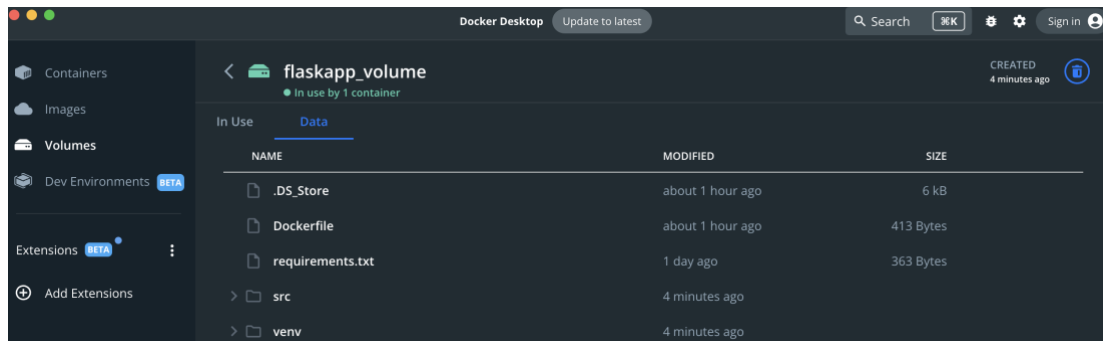
Una vez el usuario haya accedido a los enlaces, se generarán los gráficos y bases de datos.

```
~/Documents/MASTER_DS/compus/flask_ETL_sw
docker exec 1f454379fa70 ls
Dockerfile
especies.db
pelis.db
people.db
planetas.db
requirements.txt
src
top_10_naves_caras.jpeg
top_10_naves_caras_sinDS.jpeg
top_10_planetas_habitantes.jpeg
venv
```

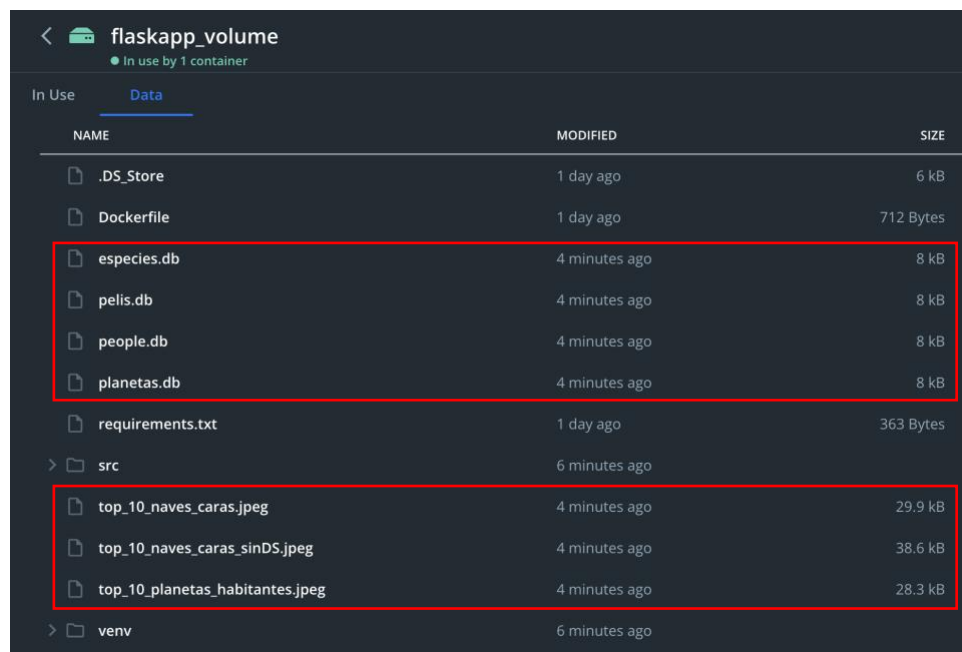
- Vemos que tiene todos los archivos y carpetas de la aplicación, incluidos las imágenes y las bases de datos que se han creado después de ejecutar la aplicación y acceder a todos los enlaces.

A través de la herramienta Docker Desktop, podemos consultar los volúmenes y descargarlos en nuestra máquina local, aunque borremos el contenedor.

- Antes de acceder a los enlaces de la web:



- Después de acceder a todos los enlaces de la web:



Podemos descargar localmente todo lo que está dentro del volumen:

